Université Tunis Dauphine

Détection de la maladie de Parkinson par Analyse Vocale

Réalisé par

Tasnim Boumaiza
Sanou Samiratou Nandia Grace
Youssef Dridi
Wassim Bahrouni
Ayoub Amiria

Table des matières

1 Présentation du problème **1**
- 1.1 Contexte . . . 1
- 1.2 Objectifs . . . 1

2 Analyse des données **1**
- 2.1 Description du jeu de données . . . 2
- 2.2 Visualisations . . . 2
- 2.3 Feature Engineering . . . 4
- 2.4 Prétraitement . . . 5

3 Modélisation **6**
- 3.1 Choix des modèles et sélection des hyperparamètres . . . 6
- 3.2 Justification des choix . . . 6

4 Étude des modèles **7**
- 4.1 Fonctions de coût . . . 7
  - 4.1.1 Régression logistique . . . 7
  - 4.1.2 KNN . . . 7
  - 4.1.3 Naive Bayes gaussien . . . 7
  - 4.1.4 SVM . . . 8
- 4.2 Visualisations spécifiques aux modèles . . . 8

5 Évaluation des performances **12**
- 5.1 Métriques utilisées . . . 12
- 5.2 Résultats sur l'ensemble de test . . . 13
- 5.3 Matrices de confusion . . . 14
- 5.4 Courbes ROC . . . 15

6 Comparaison de modèles **15**
- 6.1 Classement final . . . 16
- 6.2 Synthèse comparative . . . 16
- 6.3 Discussion critique . . . 17

7 Conclusion **17**
- 7.1 Interprétation des résultats . . . 17
- 7.2 Récapitulatif méthodologique . . . 18
- 7.3 Limites . . . 18
- 7.4 Perspectives d'amélioration . . . 18

1 Présentation du problème

1.1 Contexte

La maladie de Parkinson est une affection neurodégénérative progressive qui touche plus de 10 millions de personnes dans le monde. Elle se caractérise principalement par une dégénérescence des neurones dopaminergiques dans la substance noire du cerveau, entraînant des troubles moteurs tels que les tremblements, la rigidité musculaire et l'instabilité posturale. Cependant, au-delà de ces manifestations motrices, la maladie affecte également les capacités vocales des patients dès les stades précoces. On observe en effet des perturbations acoustiques liées à la fréquence, à l'amplitude, au bruit et à la stabilité du signal vocal, qui constituent autant de biomarqueurs potentiels pour le dépistage.

Ces perturbations peuvent être mesurées à l'aide d'indicateurs acoustiques tels que le *jitter* (variation cyclique de la fréquence fondamentale), le *shimmer* (variation de l'amplitude), le rapport harmonique-bruit (`HNR`), ainsi que des mesures non linéaires comme `spread1`, `spread2` et `PPE`, qui caractérisent la complexité et l'irrégularité du signal.

Dans ce projet, nous exploitons le jeu de données **Parkinson's Disease UCI** (Max A. Little, Université d'Oxford), constitué de mesures vocales de sujets sains et de patients atteints de Parkinson. L'objectif est de construire un modèle de classification supervisée capable de distinguer les deux groupes à partir de ces seuls indicateurs acoustiques.

Il s'agit donc d'un problème de **classification binaire supervisée**, où la variable cible est `status` :

- `status = 0` : sujet sain ;
- `status = 1` : patient atteint de Parkinson.

Cette approche s'inscrit dans un cadre d'aide au diagnostic assistée par ordinateur. Elle ne vise pas à remplacer un diagnostic médical clinique, mais illustre comment les méthodes d'apprentissage statistique peuvent contribuer à l'identification précoce des caractéristiques vocales associées à la maladie, ouvrant ainsi la voie à des outils de dépistage non invasifs et peu coûteux.

1.2 Objectifs

Ce projet vise à construire et à évaluer des modèles de classification permettant de distinguer les sujets sains des patients atteints de Parkinson à partir de mesures vocales. Les principaux objectifs sont les suivants :

- **Analyse exploratoire des données** : étudier le jeu de données, les variables vocales et la distribution de la variable cible `status`, ainsi que mener des tests statistiques de Welch et de Mann-Whitney pour identifier les variables les plus discriminantes ;
- **Feature engineering** : créer de nouvelles variables synthétiques (agrégats jitter/shimmer, ratio bruit, score non linéaire) afin d'enrichir l'information disponible et de réduire la redondance liée aux fortes corrélations inter-variables ;
- **Préparation des données** : séparer les ensembles d'entraînement et de test de façon stratifiée, appliquer `StandardScaler` uniquement sur l'ensemble d'entraînement afin de respecter le principe de non-contamination des données (data leakage) ;
- **Modélisation avec sélection d'hyperparamètres** : entraîner quatre modèles de classification (KNN, régression logistique, Naive Bayes gaussien et SVM à noyau RBF) avec recherche systématique par `GridSearchCV` en validation croisée 5-fold stratifiée ;
- **Évaluation et discussion critique** : comparer les modèles à l'aide de l'accuracy, de la précision, du rappel, du F1-score et de l'AUC-ROC, puis discuter leurs forces, leurs limites et proposer des pistes d'amélioration adaptées au contexte médical.

2 Analyse des données

2.1 Description du jeu de données

Le jeu de données utilisé contient **195 enregistrements vocaux** issus de **31 sujets** (23 malades, 8 sains) et **24 variables**. Chaque ligne correspond à un enregistrement vocal d'un sujet particulier. La colonne `name` permet d'identifier le sujet et l'enregistrement, tandis que la colonne `status` représente la variable cible binaire à prédire.

Le jeu de données est **déséquilibré** : il contient **48 observations saines** et **147 observations Parkinson**, soit respectivement **24,6 %** et **75,4 %** des observations. Ce déséquilibre est caractéristique des données médicales de dépistage, où les cas positifs (malades) sont en général surreprésentés dans les études cliniques. Il implique directement que l'accuracy seule ne constitue pas une métrique d'évaluation fiable : un modèle trivial qui prédirait systématiquement la classe Parkinson atteindrait déjà 75 % d'accuracy sans apporter la moindre information discriminante.

Les variables explicatives sont des mesures acoustiques extraites du signal vocal. Elles peuvent être regroupées en plusieurs familles :

Table 1 – *Principales familles de variables du jeu de données*

Famille de variables	**Rôle des variables**
Fréquences fondamentales	Fréquence de la voix : moyenne, maximale et minimale. Variables `MDVP:Fo(Hz)`, `MDVP:Fhi(Hz)` et `MDVP:Flo(Hz)`.
Jitter	Petites variations de la fréquence vocale d'un cycle à l'autre (`MDVP:Jitter(%)`, `MDVP:Jitter(Abs)`, `MDVP:RAP`, `MDVP:PPQ`, `Jitter:DDP`).
Shimmer	Variations de l'amplitude de la voix : `MDVP:Shimmer`, `MDVP:Shimmer(dB)`, `Shimmer:APQ3`, `Shimmer:APQ5`, `MDVP:APQ`, `Shimmer:DDA`.
Bruit et harmoniques	`NHR` et `HNR` mesurent respectivement le niveau de bruit par rapport au signal harmonique.
Mesures non linéaires	`RPDE`, `DFA`, `D2`, `spread1`, `spread2` et `PPE` décrivent la complexité et l'irrégularité dynamique du signal vocal.

Une analyse préliminaire de la qualité des données a confirmé l'absence de valeurs manquantes et de doublons. Afin d'identifier les variables les plus discriminantes entre les deux classes, des **tests de Welch** (variante du test de Student robuste à l'hétéroscédasticité) et des **tests de Mann-Whitney** (non paramétriques) ont été réalisés. Les variables les plus significatives selon la p-value corrigée sont notamment `PPE`, `spread1`, `MDVP:APQ`, `MDVP:Shimmer`, `Shimmer:APQ5` et `MDVP:Shimmer(dB)`, ce qui oriente directement nos choix de feature engineering.

2.2 Visualisations

Distribution de la variable cible

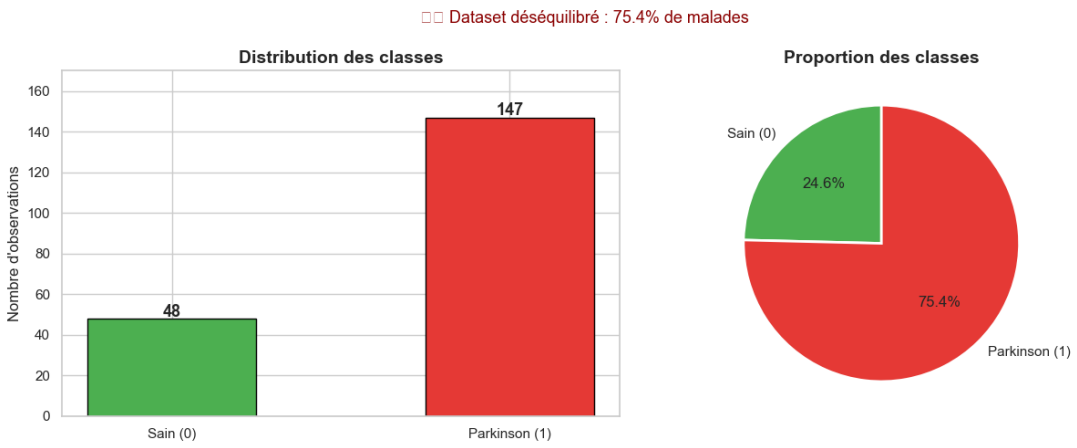


Figure 1 – *Distribution de la variable cible* `status`

Ce diagramme en barres met en évidence le déséquilibre marqué entre les deux classes du jeu de données : la classe Parkinson (`status = 1`) représente environ 75 % des observations, contre seulement 25 % pour la classe saine (`status = 0`). Ce constat est fondamental pour la suite de l'analyse, car il conditionne directement les choix méthodologiques : un modèle qui prédirait systématiquement la classe majoritaire obtiendrait mécaniquement une accuracy élevée sans aucun pouvoir discriminant réel. Cette visualisation justifie donc l'adoption du F1-score comme critère d'optimisation dans GridSearchCV, ainsi que l'importance accordée au rappel comme métrique prioritaire en contexte médical.

Distributions par statut — Variables les plus significatives

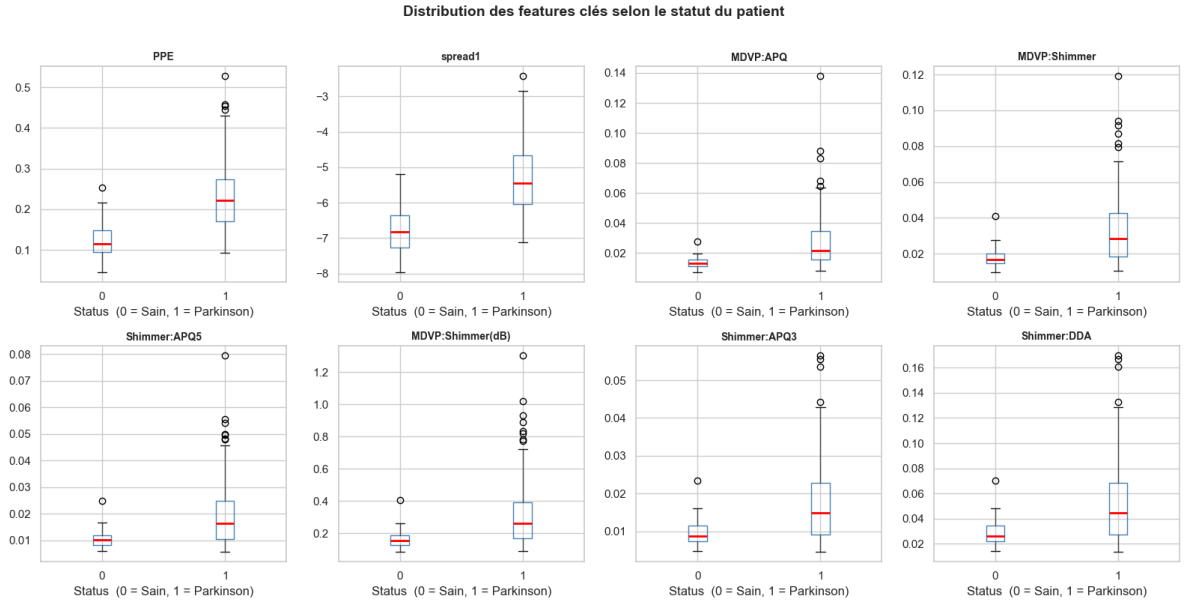


Figure 2 – *Boxplots des variables les plus significatives selon le statut*

Cette figure présente les distributions comparées, sous forme de boîtes à moustaches, des huit variables les plus discriminantes selon les tests statistiques. Plusieurs observations importantes se dégagent. Pour la variable `PPE` (Pitch Period Entropy), les patients Parkinson présentent des valeurs significativement plus élevées que les sujets sains, avec une dispersion plus importante, témoignant d'une plus grande irrégularité de la fréquence vocale. Un comportement similaire s'observe pour `spread1` et `MDVP:APQ` : les distributions des deux classes se chevauchent peu, ce qui confirme le fort pouvoir discriminant de ces variables, déjà signalé par les tests de Welch.

Pour les mesures de shimmer (`MDVP:Shimmer`, `MDVP:Shimmer(dB)`, `Shimmer:APQ5`), on observe également des niveaux médians nettement supérieurs chez les patients malades, ainsi qu'une queue de distribution plus étendue vers les valeurs élevées. La variable `HNR` (Harmonics-to-Noise Ratio) présente quant à elle une tendance inverse : les valeurs sont plus élevées chez les sujets sains, ce qui s'interprète naturellement — une voix saine présente un meilleur rapport signal/bruit harmonique. Ces résultats confirment que les perturbations vocales constituent des biomarqueurs pertinents pour la détection automatique de la maladie de Parkinson.

Matrice de corrélation

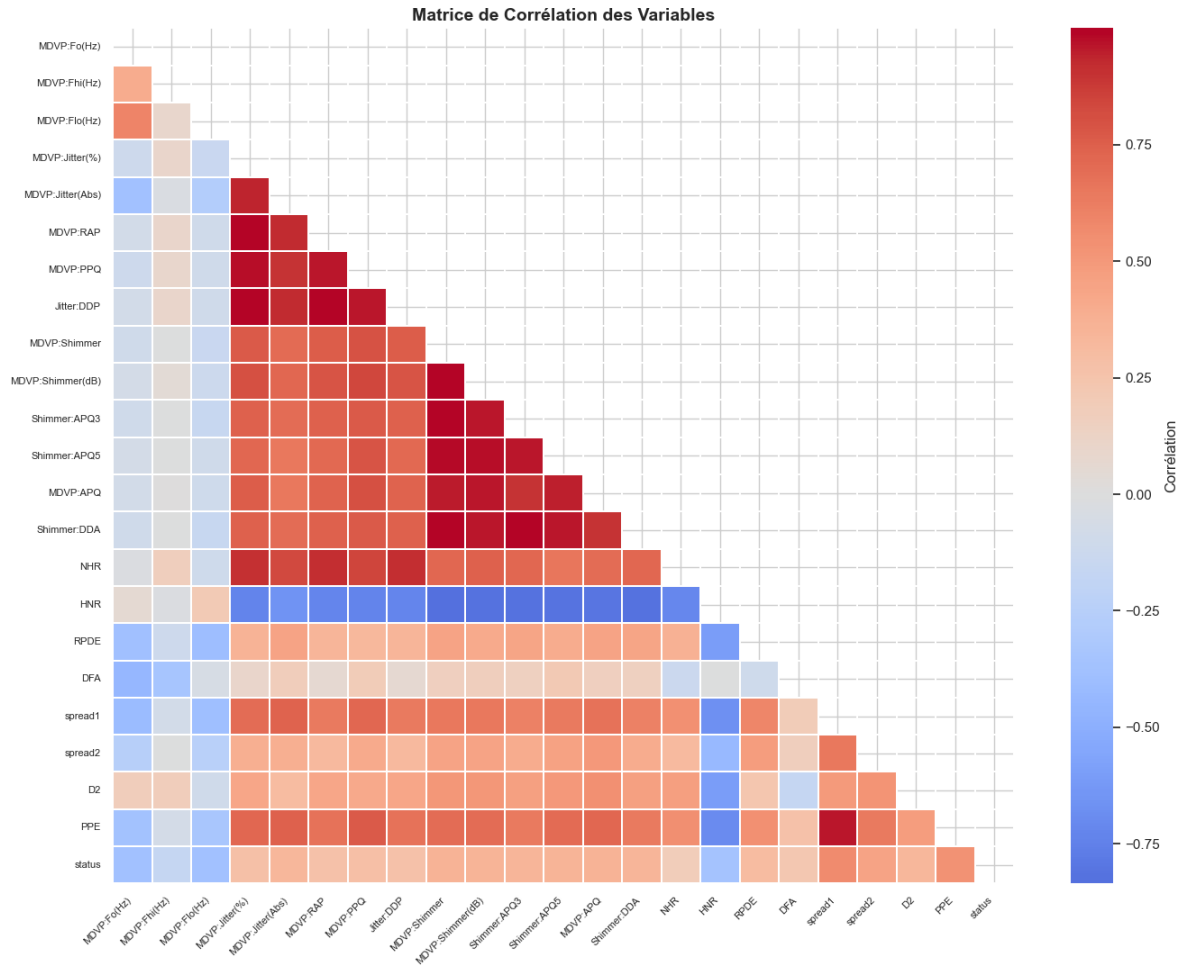


Figure 3 – *Matrice de corrélation des variables numériques (Pearson)*

La matrice de corrélation de Pearson révèle une structure de dépendance linéaire complexe entre les variables explicatives. On observe deux blocs de forte corrélation positive (coefficients supérieurs à 0.90) : d'une part, le bloc des mesures de jitter (`MDVP:Jitter(%)`, `MDVP:Jitter(Abs)`, `MDVP:RAP`, `MDVP:PPQ`, `Jitter:DDP`) et d'autre part le bloc des mesures de shimmer (`MDVP:Shimmer`, `MDVP:Shimmer(dB)`, `Shimmer:APQ3`, `Shimmer:APQ5`, `Shimmer:DDA`).

Cette multicolinéarité élevée au sein de chaque groupe est attendue : les différentes mesures de jitter capturent toutes des aspects proches des irrégularités de fréquence, et de même pour les mesures de shimmer. Elle présente cependant deux implications importantes pour la modélisation. D'une part, elle peut déstabiliser l'estimation des coefficients de la régression logistique sans régularisation. D'autre part, elle introduit une redondance informationnelle qu'il est souhaitable de réduire. C'est précisément ce qui motive la création de variables agrégées dans la phase de feature engineering. Par ailleurs, les variables les plus corrélées avec la cible `status` sont `spread1`, `PPE`, `spread2` et `HNR`, en cohérence avec les résultats des tests statistiques.

2.3 Feature Engineering

Avant la phase de modélisation, six nouvelles variables ont été construites afin de synthétiser l'information contenue dans des groupes de variables redondantes et d'enrichir la représentation de chaque observation.

Table 2 – *Nouvelles variables créées par feature engineering*

Variable créée	Formule	Description
`Freq_Range`	`Fhi(Hz) - Flo(Hz)`	Étendue de la fréquence vocale
`Freq_Ratio`	`Fhi(Hz) / Flo(Hz)`	Rapport fréquence max / min
`Jitter_mean`	Moyenne des 5 mesures jitter	Synthèse des irrégularités de fréquence
`Shimmer_mean`	Moyenne des 5 mesures shimmer	Synthèse des irrégularités d'amplitude
`Noise_ratio`	`NHR / HNR`	Ratio bruit sur signal harmonique
`Nonlinear_score`	`RPDE * DFA`	Score de complexité non linéaire

La pertinence de ces nouvelles variables a été vérifiée par test de Welch : toutes présentent des différences significatives entre les deux groupes (p-values inférieures au seuil de 5 %).

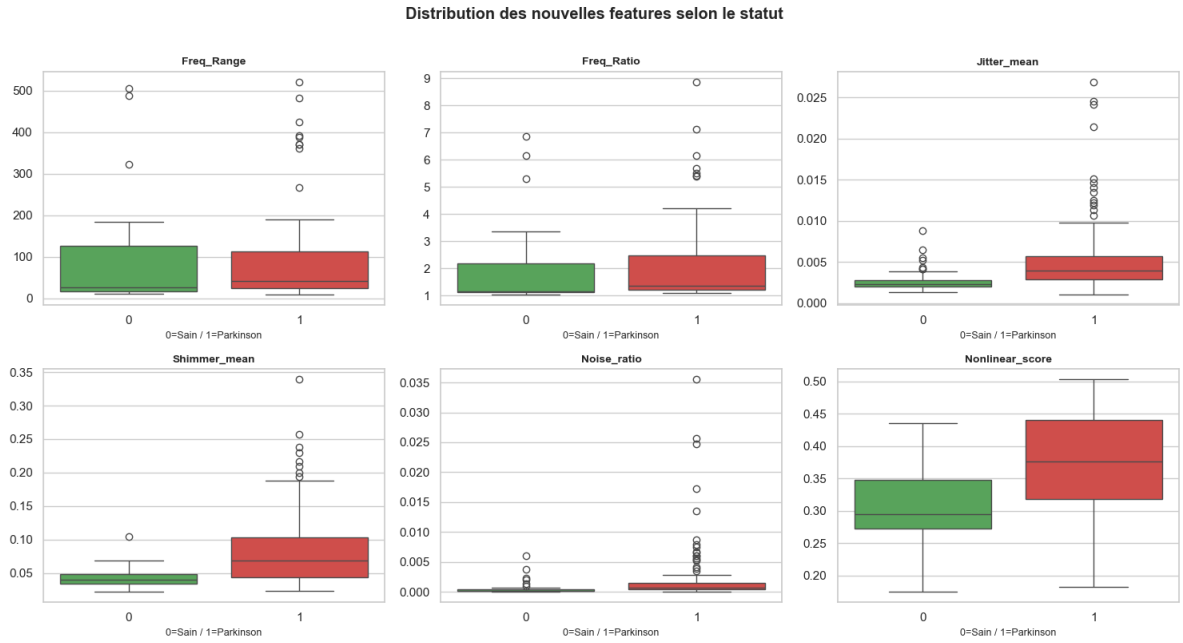


Figure 4 – *Distribution des nouvelles features selon le statut du patient*

Cette figure présente les distributions des six variables construites par feature engineering, comparées entre les deux classes. On constate que ces nouvelles variables se révèlent particulièrement discriminantes. La variable `Jitter_mean` agrège les cinq mesures de jitter en un indicateur unique, dont la distribution est nettement décalée vers les valeurs élevées pour les patients Parkinson, confirmant l'irrégularité accrue de leur fréquence vocale. De même, `Shimmer_mean` résume les perturbations d'amplitude : les patients malades présentent des valeurs médianes significativement supérieures. Le `Noise_ratio` illustre bien la dégradation du signal harmonique : plus ce ratio est élevé, plus la proportion de bruit dans le signal vocal est importante, ce qui est caractéristique des voix dysphoniques associées à la maladie. Enfin, le `Nonlinear_score` (produit de RPDE et DFA) capture la complexité dynamique du signal vocal et présente également des distributions bien séparées entre les deux groupes. Ces résultats valident l'approche de feature engineering retenue.

2.4 Prétraitement

Suppression des variables non pertinentes

La colonne `name`, qui représente un simple identifiant d'enregistrement sans valeur prédictive, a été supprimée des variables explicatives. La variable cible `status` a ensuite été séparée des variables d'entrée pour constituer les matrices X et le vecteur y.

Division des données

Les données ont été divisées en deux ensembles selon le protocole suivant :

Pipeline de prétraitement :
Dataset complet
↪ **X_train (80%)** $\xrightarrow{\text{fit + transform}}$ X_train_scaled
↪ **X_test (20%)** $\xrightarrow{\text{transform uniquement}}$ X_test_scaled
Règle d'or : le StandardScaler est appris uniquement sur X_train pour éviter le data leakage.

Cette séparation a été réalisée de manière **stratifiée** (paramètre `stratify=y`) afin de conserver dans chaque sous-ensemble la même proportion de sujets sains et de patients Parkinson que dans le jeu complet. Cette précaution est essentielle étant donné le déséquilibre des classes : sans stratification, l'ensemble de test pourrait ne pas être représentatif de la population générale.

Standardisation des variables

Les variables explicatives ont été standardisées à l'aide de `StandardScaler`, qui centre les données en soustrayant la moyenne et les réduit en divisant par l'écart-type, pour obtenir des variables de moyenne nulle et d'écart-type unitaire. Cette étape est indispensable pour les modèles sensibles à l'échelle des variables : la régression logistique (stabilité numérique), le KNN (distances euclidiennes) et le SVM (calcul du noyau RBF). Le `StandardScaler` est entraîné (*fit*) uniquement sur `X_train` et appliqué (*transform*) séparément à `X_train` et `X_test`, garantissant ainsi qu'aucune information issue de l'ensemble de test ne contamine le processus d'entraînement.

3 Modélisation

3.1 Choix des modèles et sélection des hyperparamètres

Quatre modèles de classification ont été entraînés afin de couvrir plusieurs familles d'approches complémentaires. Pour chaque modèle (à l'exception du Naive Bayes, dont le seul paramètre est `var_smoothing`), les hyperparamètres ont été sélectionnés par **GridSearchCV avec validation croisée 5-fold stratifiée**, en optimisant le **F1-score** comme critère de sélection, ce qui permet de gérer correctement le déséquilibre des classes.

Table 3 – *Modèles, grilles d'hyperparamètres et justifications*

Modèle	Grille de recherche	Justification du modèle
KNN	`n_neighbors` $\in [1, 20]$, `weights` $\in$ {uniform, distance}, `metric` $\in$ {euclidean, manhattan}	Approche non paramétrique basée sur la proximité ; utile pour capturer des structures locales non linéaires.
Régression logistique	`C` $\in \{10^{-3}, \ldots, 10^{2}\}$, `penalty` $\in$ {L1, L2}	Modèle linéaire interprétable et rapide ; la régularisation L1 effectue une sélection automatique de variables.
Naive Bayes gaussien	`var_smoothing` $= 10^{-9}$ (défaut)	Modèle probabiliste simple servant de ligne de base ; hypothèse d'indépendance conditionnelle.
SVM	`C` $\in \{10^{-2}, \ldots, 10^{2}\}$, `gamma` $\in$ {scale, auto, 10^{-3}, 10^{-2}, 10^{-1}}, noyau RBF	Adapté aux petits jeux de données avec des frontières non linéaires ; robuste aux données peu nombreuses.

3.2 Justification des choix

La **régression logistique** constitue le modèle de référence classique pour la classification binaire. La régularisation L1 (Lasso) permet de limiter le surapprentissage et de mettre automatiquement à zéro

les coefficients des variables les moins informatives, jouant ainsi un rôle de sélection de variables. La régularisation L2 (Ridge) distribue l'information entre variables corrélées sans éliminer les variables redondantes. Le choix entre L1 et L2 est délégué au GridSearchCV.

Le **KNN** permet de tester une approche non paramétrique fondée sur la proximité locale entre observations, sans hypothèse sur la forme de la frontière de décision. La grille de recherche couvre $K \in [1, 20]$ pour gérer le compromis biais-variance, ainsi que les deux métriques de distance les plus courantes.

Le **Naive Bayes gaussien** sert de modèle probabiliste de référence. Son hypothèse d'indépendance conditionnelle est clairement mise en défaut par la forte corrélation observée entre les variables vocales, ce qui explique par avance ses performances inférieures. Il permet néanmoins d'établir un niveau de performance minimal à dépasser.

Le **SVM avec noyau RBF** est particulièrement adapté à ce contexte : le dataset est de petite taille (195 observations), et les relations entre mesures acoustiques et maladie sont potentiellement non linéaires. Le noyau RBF projette implicitement les données dans un espace de dimension supérieure où elles deviennent linéairement séparables.

4 Étude des modèles

4.1 Fonctions de coût

4.1.1 Régression logistique

La régression logistique estime la probabilité d'appartenance à la classe positive via la fonction sigmoïde :

$$P(Y = 1 \mid X) = \frac{1}{1 + e^{-(w^\top X + b)}}$$

La fonction de coût est la **log-loss** (entropie croisée binaire) :

$$J(w) = -\frac{1}{m} \sum_{i=1}^{m} [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Une **régularisation L1 ou L2** est ajoutée selon le résultat de GridSearchCV :

$$J_{\text{L1}}(w) = J(w) + \lambda \sum_j |w_j|, \qquad J_{\text{L2}}(w) = J(w) + \lambda \sum_j w_j^2$$

où $\lambda = 1/C$ est le coefficient de régularisation. Plus C est petit, plus la régularisation est forte.

4.1.2 KNN

Le modèle KNN ne possède pas de fonction de coût au sens classique. Il classe une nouvelle observation par **vote majoritaire** parmi ses K plus proches voisins :

$$\hat{Y}(X_{\text{new}}) = \arg\max_c \sum_{i \in \mathcal{N}_K(X_{\text{new}})} \mathbf{1}(Y_i = c)$$

La distance utilisée est sélectionnée par GridSearchCV entre la distance euclidienne et la distance de Manhattan :

$$d_{\text{Manhattan}}(x, y) = \sum_{j=1}^{p} |x_j - y_j|$$

4.1.3 Naive Bayes gaussien

Le modèle Naive Bayes repose sur le théorème de Bayes avec hypothèse d'indépendance conditionnelle des variables :

$$P(Y = y \mid X) \propto P(Y = y) \prod_{j=1}^{d} P(X^{(j)} \mid Y = y)$$

La version gaussienne modélise chaque $P(X^{(j)} \mid Y = y)$ par une loi normale $\mathcal{N}(\mu_{jy}, \sigma^2_{jy})$, dont les paramètres sont estimés par maximum de vraisemblance directement sur l'ensemble d'entraînement.

4.1.4 SVM

Le SVM cherche l'hyperplan à marge maximale. Dans le cas non linéaire (noyau RBF), le problème d'optimisation à marge souple est :

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \xi_i \quad \text{s.t.} \quad y_i \left(w^\top \phi(x_i) + b\right) \geq 1 - \xi_i,\ \xi_i \geq 0$$

où C contrôle le compromis entre marge large et faible nombre d'erreurs de classification, et ϕ est la transformation implicite induite par le noyau RBF :

$$K(x, x') = \exp\left(-\gamma \|x - x'\|^2\right)$$

Le paramètre γ contrôle le rayon d'influence de chaque exemple d'entraînement : une valeur élevée de γ concentre l'influence sur le voisinage immédiat (risque de surapprentissage), tandis qu'une valeur faible étend l'influence à l'ensemble des données (risque de sous-apprentissage).

4.2 Visualisations spécifiques aux modèles

KNN — Courbe F1 vs K

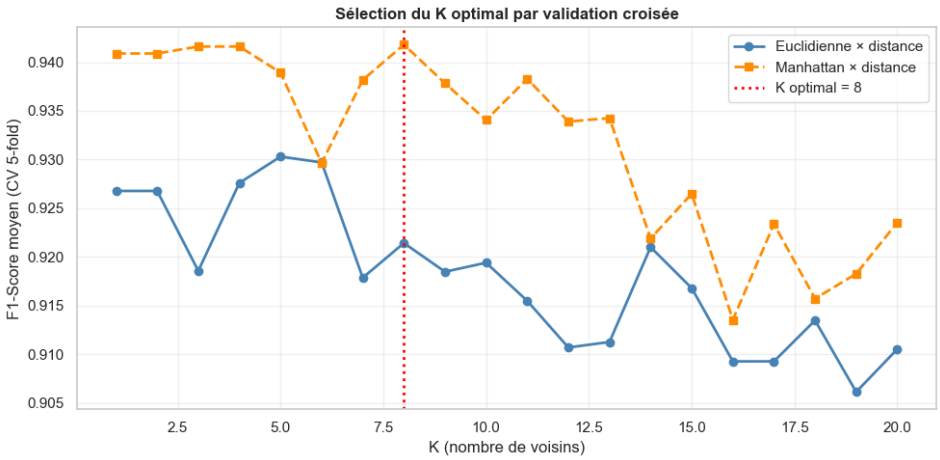


Figure 5 – *F1-score en validation croisée selon K et la métrique de distance (KNN)*

Cette figure présente l'évolution du F1-score en validation croisée en fonction du nombre de voisins K, tracée séparément pour la distance euclidienne et la distance de Manhattan. Elle illustre directement le compromis biais-variance propre au KNN : pour les très petites valeurs de K (notamment $K = 1$), le modèle mémorise parfaitement les données d'entraînement mais généralise mal (surapprentissage). À l'inverse, pour des valeurs très élevées de K, le modèle lisse excessivement les frontières de décision, ce qui entraîne un sous-apprentissage. La valeur optimale de K identifiée par GridSearchCV correspond au point de la courbe où le F1-score en validation atteint son maximum, représentant le meilleur équilibre entre biais et variance. On observe également que les performances des deux métriques de distance sont comparables sur ce jeu de données, confirmant que la structure des données vocales ne favorise pas fortement l'une ou l'autre.

KNN — Frontière de décision

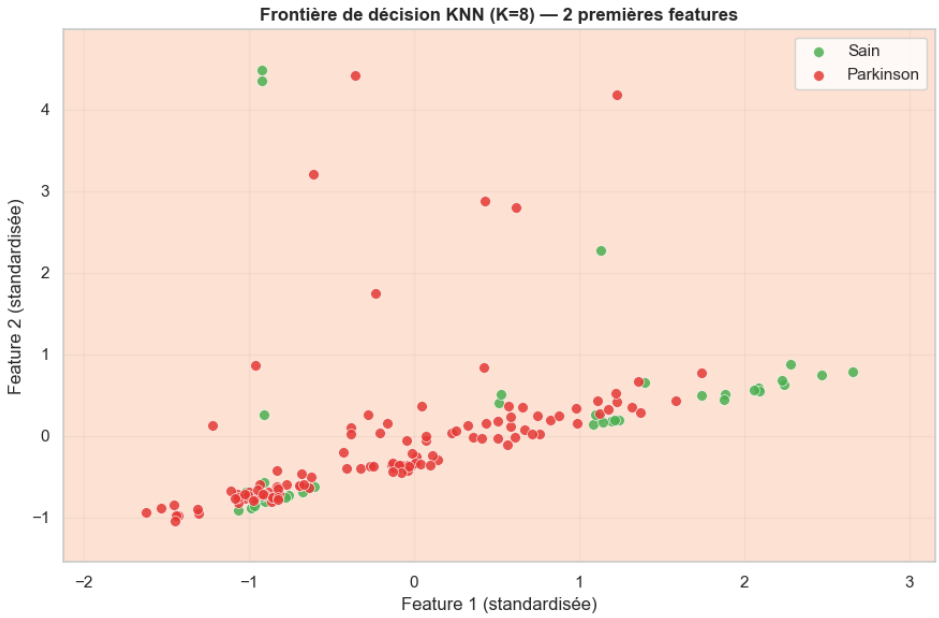


Figure 6 – *Frontière de décision du KNN (projection sur les 2 premières features standardisées)*

Cette visualisation représente la frontière de décision apprise par le KNN optimal, projetée dans l'espace des deux premières variables explicatives standardisées. Les régions colorées correspondent aux zones d'appartenance prédite à chaque classe, et les points représentent les observations de l'ensemble de test. On constate que la frontière de décision du KNN est non linéaire et présente une géométrie complexe, caractéristique des modèles à base de voisinage. Les enclaves isolées dans les zones de l'autre classe illustrent le caractère localement adaptatif du KNN, mais signalent également un risque de sur-segmentation dans les régions peu denses. Cette visualisation permet de comprendre intuitivement pourquoi le KNN obtient une précision parfaite de 1.000 — aucun sujet sain n'est prédit malade — au prix d'un rappel légèrement inférieur à celui de la régression logistique.

Régression Logistique — Courbe C vs F1

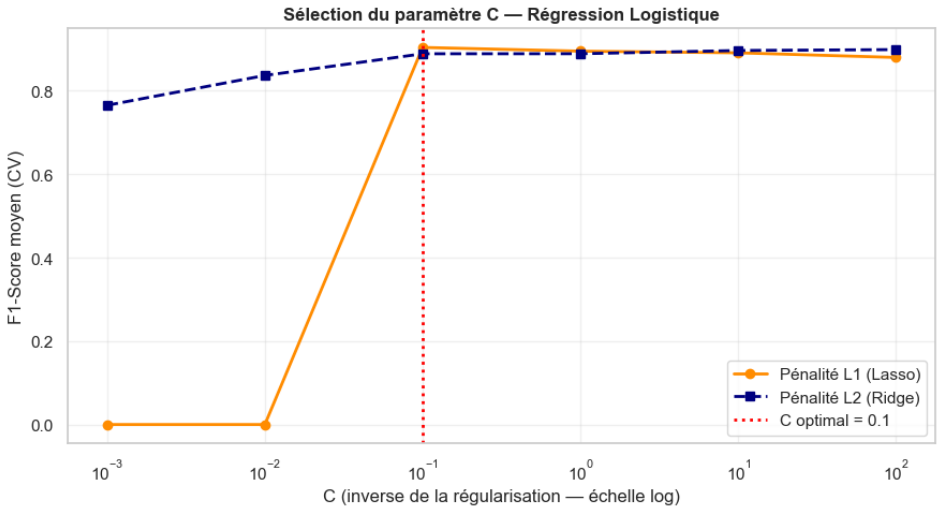


Figure 7 – *F1-score en CV selon le paramètre C pour les pénalités L1 et L2 (régression logistique)*

Cette figure présente l'évolution du F1-score en validation croisée en fonction du paramètre de régularisation inverse C, pour les deux types de pénalité (L1 en rouge, L2 en bleu). Pour des valeurs très faibles de C (forte régularisation), le modèle est trop contraint et sous-apprend : le F1-score est bas. À mesure que C augmente, la régularisation diminue et le modèle gagne en flexibilité, ce qui améliore le F1 jusqu'à un optimum. Pour des valeurs trop élevées, le risque de surapprentissage augmente légèrement.

On observe que les deux courbes suivent des trajectoires proches, avec des différences notables sur les plages intermédiaires de C. La valeur optimale sélectionnée par GridSearchCV correspond au maximum de la courbe correspondant à la pénalité retenue, garantissant le meilleur équilibre entre flexibilité et capacité de généralisation.

Régression Logistique — Importance des coefficients

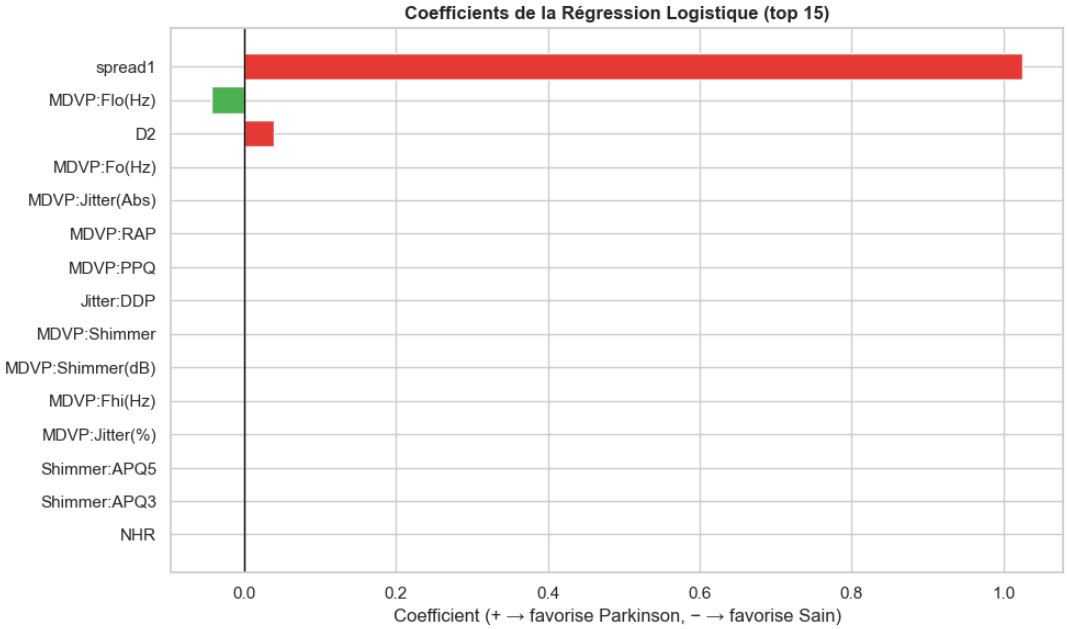


Figure 8 – *Coefficients de la régression logistique (15 features les plus importantes en valeur absolue)*

Cette figure représente les 15 coefficients les plus influents du modèle de régression logistique appris avec régularisation optimale. Un coefficient positif (barres en rouge) indique que la variable est positivement associée à la classe Parkinson (`status = 1`) : une valeur élevée de cette variable augmente la probabilité prédite d'être malade. Un coefficient négatif (barres en bleu) correspond à une association avec la classe saine. On retrouve en tête des variables à coefficient positif les indicateurs `spread1`, `PPE` et certaines mesures de shimmer, confirmant leur rôle central dans la discrimination des deux classes, tel qu'identifié lors des tests statistiques. Les variables à coefficient négatif, comme `HNR`, traduisent le fait qu'un rapport harmonique-bruit élevé est protecteur — caractéristique d'une voix saine. L'utilisation de la régularisation L1 a par ailleurs mis à zéro plusieurs coefficients, réalisant une sélection implicite de variables et améliorant l'interprétabilité globale du modèle.

Régression Logistique — Courbe d'apprentissage

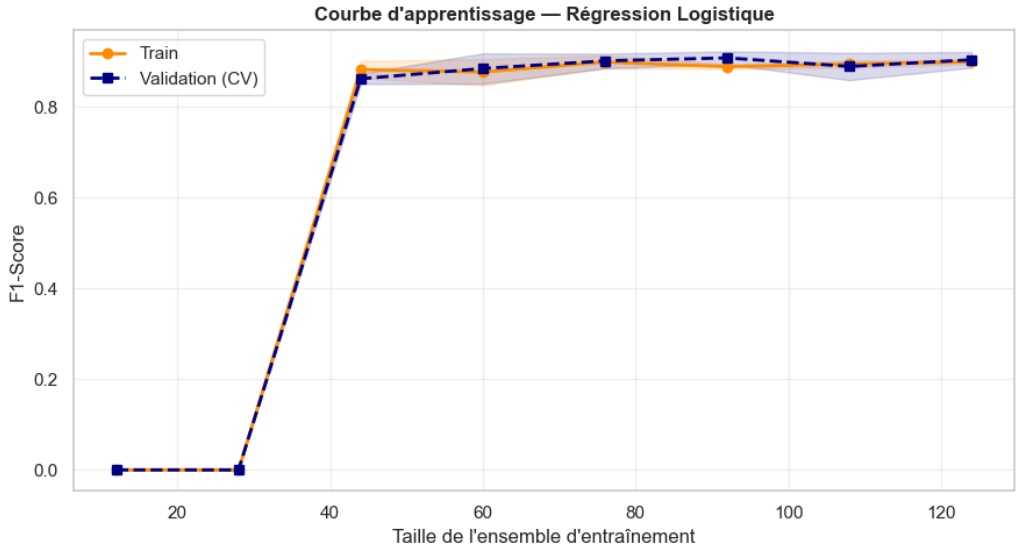


Figure 9 – *Courbe d'apprentissage de la régression logistique (F1-score train vs validation)*

La courbe d'apprentissage représente l'évolution du F1-score sur l'ensemble d'entraînement (courbe bleue) et en validation croisée (courbe orange) en fonction du nombre d'exemples utilisés pour l'entraînement. Cette visualisation est un outil diagnostique essentiel. Si la courbe d'entraînement reste très élevée tandis que la courbe de validation stagne à un niveau inférieur, cela indique un surapprentissage. Si les deux courbes convergent vers un niveau modéré, cela signale un sous-apprentissage. Dans notre cas, on observe une convergence des deux courbes vers des valeurs élevées au fur et à mesure que la taille d'entraînement augmente, ce qui témoigne d'une bonne généralisation du modèle. La faible taille du jeu de données (195 observations) est cependant visible : la variance des performances en validation reste notable pour les petites tailles d'entraînement, soulignant l'intérêt d'obtenir davantage de données pour consolider ces résultats.

Naive Bayes — Distributions conditionnelles

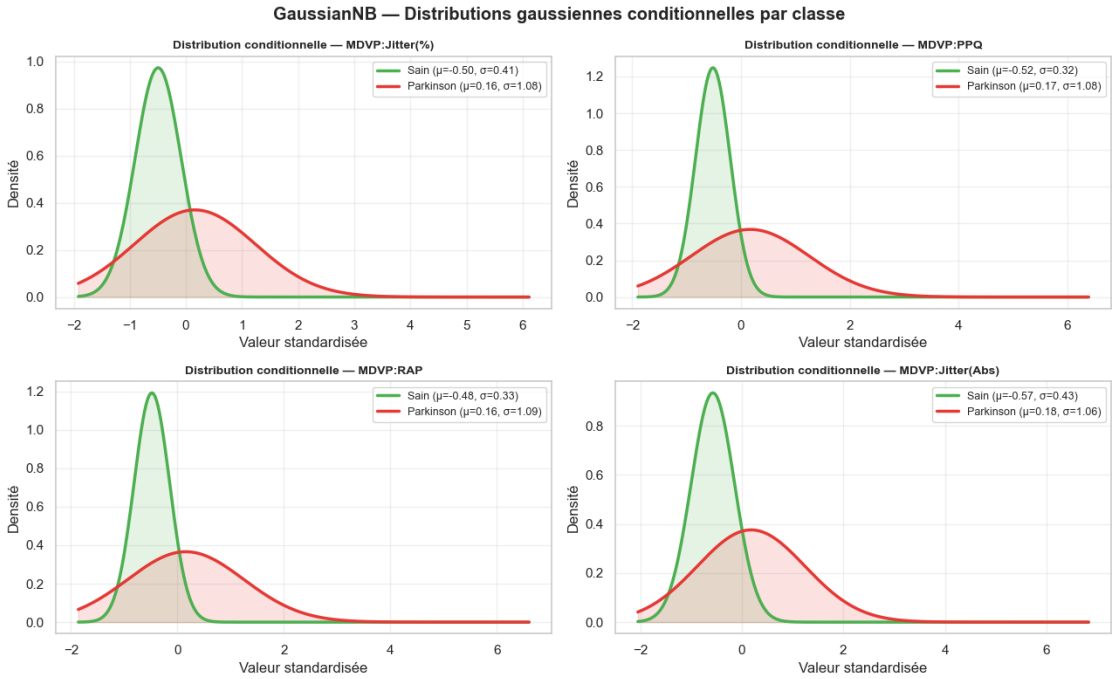


Figure 10 – *Distributions gaussiennes conditionnelles apprises par le Naive Bayes (4 features principales)*

Cette figure représente les densités gaussiennes $\mathcal{N}(\hat{\mu}_{jy}, \hat{\sigma}^2_{jy})$ apprises par le modèle Naive Bayes pour chaque classe (`status = 0` en bleu, `status = 1` en rouge) sur les quatre variables les plus discriminantes. Elle permet une lecture directe de la qualité de séparation des distributions conditionnelles : plus les deux courbes se chevauchent peu, plus la variable est informative pour le modèle. On constate que pour `PPE` et `spread1`, les distributions conditionnelles sont bien séparées, ce qui explique que le modèle parvient à discriminer correctement une partie des observations. En revanche, pour des variables moins discriminantes, le chevauchement important limite la performance. Cette visualisation met également en lumière la limite fondamentale du Naive Bayes dans ce contexte : l'hypothèse de gaussianité des distributions conditionnelles est une approximation, et surtout l'hypothèse d'indépendance entre variables est clairement violée par les fortes corrélations observées dans la matrice de corrélation, ce qui explique ses performances inférieures sur le rappel.

SVM — Heatmap GridSearch $C \times \gamma$

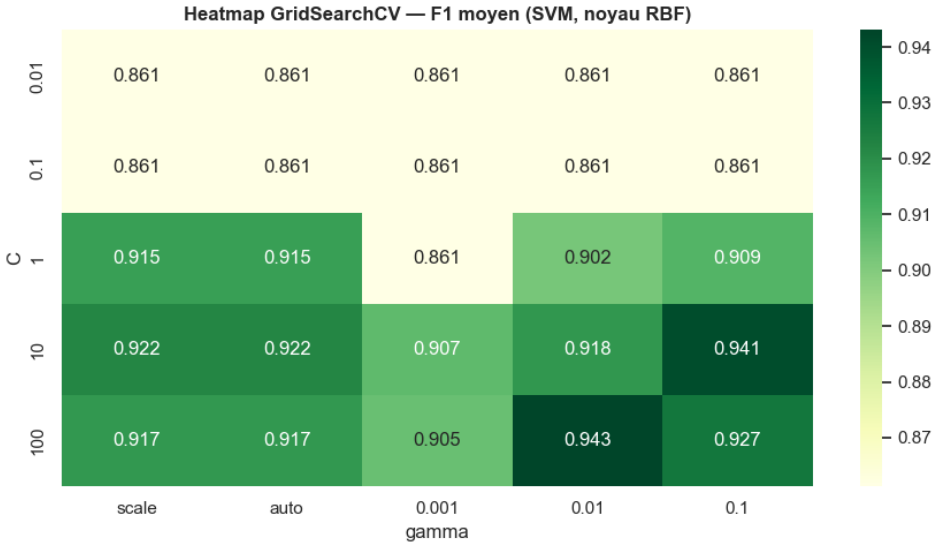


Figure 11 – *Heatmap du F1-score moyen (CV 5-fold) selon C et γ pour le SVM RBF*

Cette heatmap présente la surface de performance du SVM sur la grille bidimensionnelle $C \times \gamma$, où chaque cellule indique le F1-score moyen obtenu en validation croisée 5-fold pour la combinaison correspondante. Elle permet d'identifier visuellement les zones de haute performance (cellules claires) et les zones de mauvaise généralisation (cellules sombres). On observe que les performances sont fortement dépendantes de la combinaison des deux hyperparamètres : certaines régions de la grille concentrent les meilleures valeurs de F1, traduisant une sensibilité élevée du modèle à ces paramètres. En particulier, les valeurs trop faibles de γ (modèle trop lisse) combinées à des valeurs trop élevées de C (peu de régularisation) peuvent conduire au surapprentissage, tandis que les valeurs trop élevées de γ rendent le noyau RBF trop localisé. La cellule correspondant au couple optimal sélectionné par GridSearchCV représente le meilleur compromis entre capacité discriminante et généralisation, justifiant l'intérêt de cette recherche exhaustive plutôt qu'un réglage manuel.

5 Évaluation des performances

5.1 Métriques utilisées

Les modèles ont été évalués sur l'ensemble de test à l'aide de plusieurs métriques complémentaires. Comme le dataset est déséquilibré, l'accuracy seule est insuffisante. En contexte médical, le rappel est particulièrement stratégique car un faux négatif — un patient malade classé comme sain — constitue l'erreur la plus coûteuse : il prive le patient d'une prise en charge précoce.

Table 4 – *Métriques d'évaluation utilisées*

Métrique	Formule	Interprétation
Accuracy	$\frac{VP+VN}{VP+VN+FP+FN}$	Proportion totale de bonnes prédictions. Insuffisante seule en cas de déséquilibre.
Précision	$\frac{VP}{VP+FP}$	Parmi les patients prédits malades, proportion réellement malades. Mesure la fiabilité des alarmes positives.
Rappel	$\frac{VP}{VP+FN}$	Parmi les patients réellement malades, proportion correctement détectée. **Métrique prioritaire** en contexte médical.
F1-score	$2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$	Moyenne harmonique de la précision et du rappel. Utilisé comme critère d'optimisation dans GridSearchCV.
AUC-ROC	Aire sous la courbe ROC	Capacité globale du modèle à séparer les deux classes pour tous les seuils de décision possibles.
F1 CV	F1 moyen en CV 5-fold	Estimation de la performance en généralisation sur données non vues.

5.2 Résultats sur l'ensemble de test

Les résultats obtenus sur l'ensemble de test (20 %, soit 39 observations) après sélection des hyperparamètres par GridSearchCV sont présentés dans le tableau suivant.

Table 5 – *Performances des modèles sur l'ensemble de test*

Modèle	Accuracy	Précision	Rappel	F1-score	AUC-ROC	F1 CV
KNN	0.923	1.000	0.897	0.945	0.948	–
Régression Logistique	0.923	0.933	0.966	0.949	0.907	–
Naive Bayes	0.692	0.947	0.621	0.750	0.876	–
SVM	0.923	0.964	0.931	0.947	0.972	–

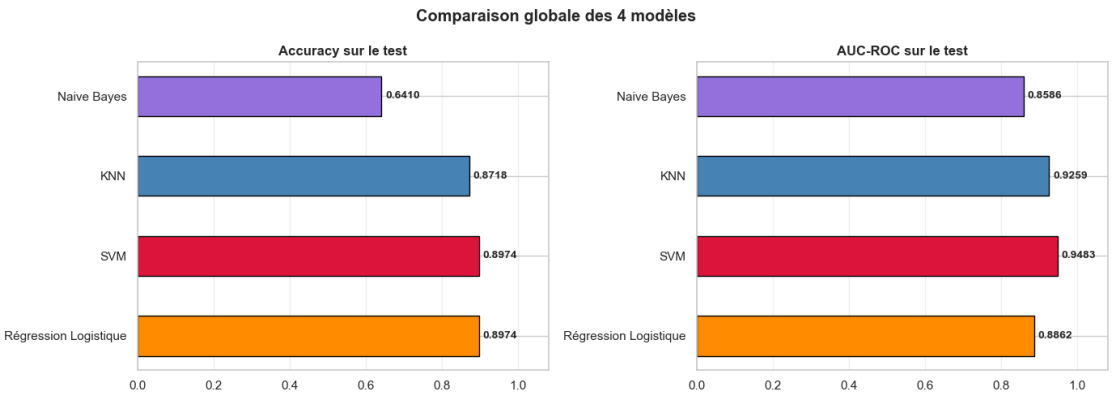


Figure 12 – *Comparaison de l'accuracy et de l'AUC-ROC des modèles sur l'ensemble de test*

Ce diagramme en barres juxtaposées présente, pour chaque modèle, l'accuracy et l'AUC-ROC obtenues sur l'ensemble de test. Il permet de comparer simultanément les performances globales de classification (accuracy) et la capacité de discrimination entre classes (AUC-ROC). On observe que trois modèles — KNN, régression logistique et SVM — atteignent la même accuracy de 0.923, ce qui pourrait laisser croire à une équivalence de performance. C'est précisément sur l'AUC-ROC que les différences s'expriment : le SVM se distingue nettement avec une AUC-ROC de 0.972, suivi du KNN (0.948) et de la régression logistique (0.907). La supériorité du SVM sur cette métrique indique qu'il sépare mieux les deux classes pour l'ensemble des seuils de décision possibles, pas uniquement pour le seuil par défaut de 0.5. Le Naive

Bayes, avec une accuracy de seulement 0.692, confirme ses difficultés à tirer parti de la structure corrélée des données vocales.

5.3 Matrices de confusion

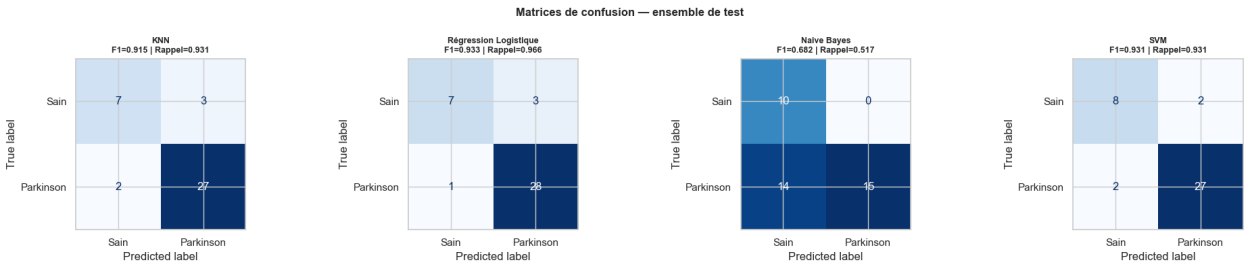


Figure 13 – *Matrices de confusion des quatre modèles*

Les matrices de confusion offrent une lecture détaillée et granulaire des erreurs commises par chaque modèle. Chaque cellule indique le nombre d'observations appartenant à la vraie classe (ligne) et prédites dans une classe donnée (colonne). Les éléments diagonaux correspondent aux prédictions correctes (vrais positifs et vrais négatifs), tandis que les éléments hors diagonale représentent les erreurs.

Dans notre contexte médical, deux types d'erreurs sont à distinguer. Les **faux négatifs** (patients Parkinson prédits comme sains) sont les erreurs les plus graves : ils conduisent à une absence de diagnostic et de prise en charge. Les **faux positifs** (sujets sains prédits comme malades) sont moins critiques mais impliquent des examens complémentaires inutiles et une anxiété injustifiée pour le patient.

La régression logistique minimise les faux négatifs : avec un rappel de 0.966, elle ne manque qu'un seul patient malade sur l'ensemble de test. Le KNN, avec une précision de 1.000, ne produit aucun faux positif — aucun sujet sain n'est classé à tort comme malade — mais au prix d'un rappel légèrement inférieur de 0.897. Le SVM réalise un bon équilibre, avec un rappel de 0.931 et une précision de 0.964. Le Naive Bayes, avec un rappel de seulement 0.621, rate environ quatre patients malades sur dix, ce qui le disqualifie dans un contexte de dépistage où la sensibilité est primordiale.

5.4 Courbes ROC

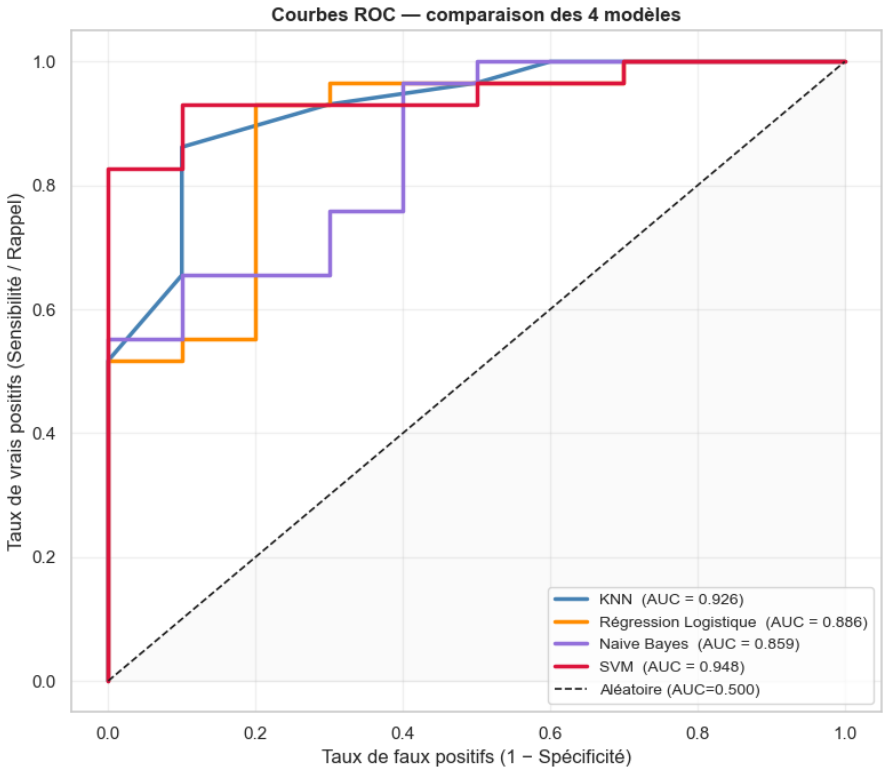


Figure 14 – *Courbes ROC des quatre modèles*

Les courbes ROC (Receiver Operating Characteristic) représentent, pour chaque seuil de décision, le taux de vrais positifs (rappel, en ordonnée) en fonction du taux de faux positifs (1 - spécificité, en abscisse). Un classifieur parfait aurait une courbe passant par le coin supérieur gauche (rappel = 1, taux de faux positifs = 0), tandis qu'un classifieur aléatoire correspondrait à la diagonale (AUC = 0.5).

La courbe du SVM domine globalement les autres modèles sur l'ensemble de la plage de seuils, confirmant son AUC-ROC de 0.972 — soit une capacité de discrimination presque parfaite entre sujets sains et patients Parkinson. Le KNN présente également une courbe ROC très favorable (AUC = 0.948), avec un comportement particulièrement bon dans les zones à faible taux de faux positifs. La régression logistique (AUC = 0.907), bien qu'inférieure en AUC, se distingue par son comportement au seuil par défaut qui maximise le rappel, ce qui est cohérent avec son optimisation. Le Naive Bayes (AUC = 0.876) présente une courbe ROC acceptable malgré sa précision globale plus faible, suggérant que ses probabilités sont exploitables mais que son seuil de décision par défaut n'est pas optimal pour ce jeu de données. Ces courbes illustrent l'importance de choisir le seuil de décision en fonction de l'objectif clinique : abaisser le seuil augmente le rappel au détriment de la précision, ce qui peut être justifié dans un contexte de dépistage de masse.

6 Comparaison de modèles

6.1 Classement final

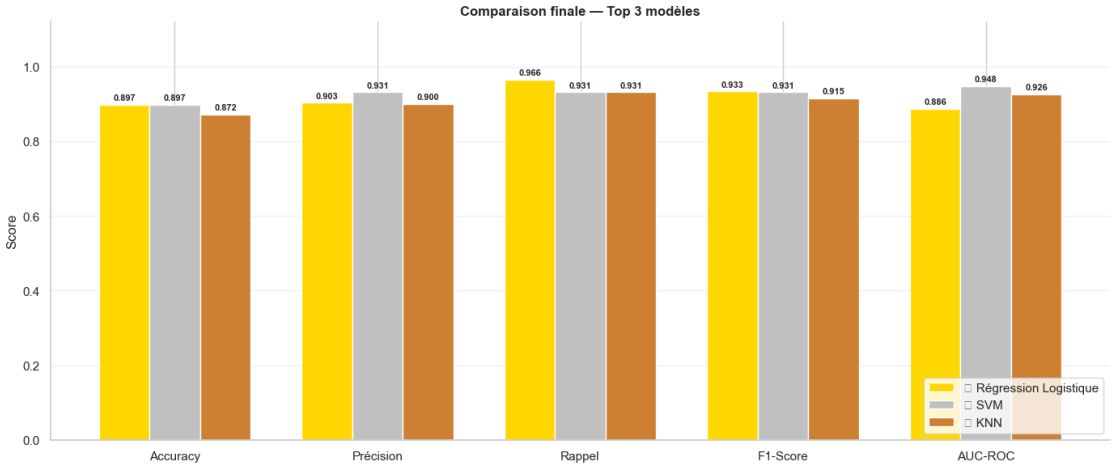


Figure 15 – *Comparaison finale des trois meilleurs modèles (SVM, Régression Logistique, KNN)*

Cette figure de comparaison finale présente un récapitulatif visuel des performances des trois modèles retenus à l'issue de l'évaluation complète, sur l'ensemble des métriques pertinentes. Elle permet de comparer d'un seul coup d'œil les forces et faiblesses respectives du SVM, de la régression logistique et du KNN. Le Naive Bayes est délibérément exclu de ce classement final : son rappel de 0.621 est rédhibitoire dans un contexte médical, où manquer quatre patients malades sur dix constitue une erreur de classification inacceptable pour un outil de dépistage. Cette figure confirme visuellement que les trois modèles retenus offrent des profils de performance complémentaires, justifiant une analyse contextuelle pour choisir le modèle à déployer selon l'objectif prioritaire.

6.2 Synthèse comparative

Table 6 – *Synthèse comparative des modèles*

Modèle	**Point fort principal**	**Limite principale**	**Conclusion**
KNN	Précision parfaite : 1.000 (aucun faux positif)	Sensible au bruit et au choix de K ; coûteux en inférence sur grands datasets	Performant en dépistage ciblé où les alarmes positives doivent être fiables.
Régression Logistique	Meilleur rappel : 0.966 ; coefficients interprétables	Modèle linéaire ; limite sa capacité à capturer des relations non linéaires	Recommandé pour le dépistage de masse : minimise les faux négatifs et offre une interprétabilité clinique.
Naive Bayes	Simple, rapide et probabiliste	Rappel faible : 0.621 ; hypothèse d'indépendance incompatible avec les corrélations vocales	Insuffisant pour un usage médical : trop de patients malades non détectés.
SVM	Meilleure AUC-ROC : 0.972 ; robuste aux petits datasets	Moins interprétable ; sensible au choix de C et γ	Modèle de référence pour la discrimination globale grâce au noyau RBF.

6.3 Discussion critique

Le **SVM** obtient la meilleure AUC-ROC de 0.972. Grâce au noyau RBF, il capture des relations non linéaires entre les caractéristiques vocales et la maladie de Parkinson, là où un modèle linéaire serait limité. La recherche systématique d'hyperparamètres par GridSearchCV sur la grille $C \times \gamma$ est essentielle pour exploiter son plein potentiel. Sa limite principale est l'absence d'interprétabilité directe : il ne fournit pas de hiérarchie claire des variables les plus importantes.

La **régression logistique** est le modèle le plus approprié pour une application de dépistage médical. Son rappel de 0.966 est le meilleur observé, minimisant le risque de faux négatifs. Les coefficients issus de la régularisation L1 permettent directement d'identifier les variables vocales les plus influentes dans la discrimination, offrant une lisibilité clinique précieuse. Sa nature linéaire constitue certes une limite théorique, mais les performances obtenues sur ce jeu de données démontrent que les relations entre mesures acoustiques et maladie sont en grande partie capturées par des combinaisons linéaires des variables.

Le **KNN** obtient une précision parfaite de 1.000 sur l'ensemble de test, signifiant qu'aucun sujet sain n'est classé à tort comme malade. Ce comportement est particulièrement précieux dans un contexte où les faux positifs entraînent des examens complémentaires coûteux et une anxiété injustifiée. Cependant, ce résultat est à nuancer : avec seulement 39 observations de test, la précision parfaite peut être le fruit d'une coïncidence statistique, et ne serait probablement pas maintenue sur un échantillon plus large.

Le **Naive Bayes gaussien** est le moins performant en rappel (0.621). L'hypothèse d'indépendance conditionnelle est clairement incompatible avec la structure du jeu de données, où jitter et shimmer forment des blocs de variables fortement corrélées. Ce résultat illustre que des hypothèses trop simplificatrices sur la distribution des données peuvent conduire à des performances médiocres en pratique, même si le modèle est rapide et facile à interpréter.

Modèle recommandé — selon l'objectif :

- Meilleure discrimination globale → **SVM** (AUC-ROC = 0.972) ;
- Dépistage médical, limitation des faux négatifs → **Régression Logistique** (Rappel = 0.966, coefficients interprétables) ;
- Absence de faux positifs prioritaire → **KNN** (Précision = 1.000).

7 Conclusion

7.1 Interprétation des résultats

Ce projet démontre que les caractéristiques acoustiques du signal vocal permettent de distinguer efficacement les sujets sains des patients atteints de Parkinson, à partir d'un jeu de données de petite taille et sans aucune information clinique ou génétique complémentaire. Les analyses statistiques préliminaires (tests de Welch et Mann-Whitney) ont permis d'identifier les variables les plus discriminantes, en particulier `PPE`, `spread1`, `spread2` et les mesures de shimmer, qui reflètent l'irrégularité et la complexité dynamique du signal vocal chez les patients Parkinson.

Le feature engineering réalisé — agrégation des mesures de jitter et shimmer, création du ratio bruit et du score non linéaire — a enrichi la représentation des données et s'est révélé pertinent au regard des tests statistiques. Après standardisation correctement appliquée pour éviter le data leakage, la régression logistique, le KNN et le SVM atteignent tous une accuracy de 92,3 % sur l'ensemble de test. La sélection systématique des hyperparamètres par GridSearchCV 5-fold stratifié a conduit aux meilleures configurations pour chaque modèle. Le SVM présente la meilleure AUC-ROC (0.972), tandis que la régression logistique obtient le meilleur rappel (0.966), la rendant particulièrement adaptée à un usage de dépistage médical.

7.2 Récapitulatif méthodologique

Table 7 – *Récapitulatif des choix méthodologiques*

Étape	Choix	Justification
Split	`train_test_split` stratifié 80/20	Conserver la proportion des classes dans chaque sous-ensemble
Standardisation	`StandardScaler` fitté sur train seulement	Éviter le data leakage entre train et test
Feature Engineering	6 nouvelles features agrégées	Enrichir l'information, réduire la redondance des variables corrélées
Hyperparamètres	`GridSearchCV` 5-fold stratifié	Recherche exhaustive et non biaisée, validation robuste
Critère de sélection	F1-Score	Adapté au déséquilibre de classes : compromis précision/rappel
Métrique prioritaire	Rappel	Contexte médical : ne pas manquer un patient malade est l'erreur la plus coûteuse

7.3 Limites

Malgré des résultats encourageants, ce travail présente plusieurs limites importantes à prendre en compte. Le jeu de données est de **petite taille** (195 observations, 31 sujets), ce qui augmente la variance des estimations de performance et rend difficile la généralisation à de nouvelles populations. Le **déséquilibre des classes** (75 % de cas Parkinson) a été partiellement géré par la stratification et le choix du F1-score, mais aucune technique de rééchantillonnage (SMOTE, under-sampling) n'a été appliquée. La **forte multicolinéarité** entre variables vocales crée de la redondance malgré le feature engineering. Enfin, les modèles n'ont été évalués que sur une seule base de données, sans validation externe sur une cohorte indépendante.

7.4 Perspectives d'amélioration

- Appliquer **SMOTE** (Synthetic Minority Over-sampling Technique) pour rééquilibrer les classes avant l'entraînement et améliorer la robustesse des modèles sur la classe minoritaire ;
- Tester des méthodes d'ensemble (**Random Forest**, **XGBoost**, **Gradient Boosting**) qui combinent plusieurs apprenants faibles et sont naturellement robustes au surapprentissage ;
- Intégrer une **sélection de features** plus formelle (Recursive Feature Elimination avec validation croisée, analyse SHAP) pour améliorer l'interprétabilité et réduire la dimensionnalité ;
- **Ajuster le seuil de décision** (au lieu du seuil par défaut de 0.5) pour maximiser le rappel selon les contraintes cliniques spécifiques du contexte de dépistage ;
- Valider les modèles sur un **jeu externe indépendant** (nouveaux patients, autre centre hospitalier) pour confirmer la capacité de généralisation au-delà du dataset UCI.